

EL ISLAH MHOMA

Ingénieur IA / LLMops — Agents autonomes, RAG souverain & sécurisation des LLM

3 systèmes IA en production | 34 400 lignes livrées | Une IA qui sait dire « je ne sais pas »

✉ el.islah.mhoma@gmail.com • 📞 07 85 94 85 44 • 🌐 el-islah-mhoma • 📶 Islah88 • 📍 IDF & Normandie • 📄 Permis B

🎓 **Diplômé et disponible immédiatement** — Bachelor validé, mémoire soutenu (août 2026), 4+ ans d'expérience. Recherche un **contrat de professionnalisation** — Bac+5 Data & I.A. (titre RNCP niveau 7), rythme **1 semaine de cours / 3 semaines en entreprise**, durée 12 à 24 mois. **Postes :** Ingénieur IA · AI Engineer · LLMops · Consultant IA.

PROFIL

Ingénieur IA orienté **production**, pas démonstration : **3 systèmes d'IA générative conçus seul et réellement utilisés**. Mon travail de fin d'études chez **VINCI Construction** — *Architecture et sécurisation d'un RAG souverain* — a produit un copilote métier de **34 400 lignes (131 tests, 176 commits, 10 ADR)** tournant **100 % en local, en air-gap** : aucune donnée ne quitte le poste. Ma valeur ajoutée n'est pas de brancher un LLM, mais de le rendre **fiable et attaquable-résistant** : garde-fous en **5 couches, ancrage vérifié > 85 %, politique d'abstention** et durcissement face aux menaces **OWASP LLM Top 10** (injection de prompt, empoisonnement, fuite de données), validé par une démarche **adversariale**. J'ai également mis en production un **agent 100 % autonome** (2 exécutions/jour, **53 sources** → CRM client, < 35 €/mois). Profil hybride : **Master 2 Data Science**, ancien responsable d'un département de **7 personnes**, 2 ans de pilotage de projets aux Nations Unies. Je code, je sécurise, et je sais parler aux métiers.

COMPÉTENCES — INTELLIGENCE ARTIFICIELLE

Agents & architectures agentiques : Agents autonomes en production, systèmes **multi-agents** (orchestration, mémoire, planification), **function calling** et utilisation d'outils externes, protocole MCP. LangGraph, LangChain, CrewAI, n8n. Cascade de modèles coût/qualité, **kill-switch**, ledger de coût temps réel.

RAG & recherche sémantique : Pipeline complet — **chunking structure-aware**, **embeddings** multilingues (Sentence-Transformers/MiniLM, PyTorch, CPU), recherche hybride Dense + BM25 avec fusion de scores, index vectoriel avec instantané disque, **pgvector**, **citations sourcées** et provenance traçable. Routeur de rôle, détection de marqueurs cross-documents.

LLM & prompting : Open source : Llama 3.1 (Ollama, local), Mistral, Groq/LLaMA 3. Propriétaires : GPT-4o, Claude Sonnet, Gemini. **Prompt engineering**, **structured output** contraint (Pydantic), few-shot / zero-shot, chaîne de raisonnement.

Sécurisation des LLM (différenciateur) : Durcissement face aux menaces **OWASP LLM Top 10** — **injection de prompt** (directe et indirecte), empoisonnement de données, fuite d'informations sensibles, dépendances non fiables. **Redteaming** et tests adversariaux (injection, zip-bomb, path traversal), quarantaine de contenus suspects, **plan de remédiation** en défense en profondeur.

Évaluation & fiabilité : **Grounding** (ancrage vérifié > 85 %, **partial ratio** normalisé), **statuts d'abstention** motivés plutôt que scores de confiance, taux de faux positifs, **131 tests** de non-régression, métriques de coût et de latence, analyse systématique des cas d'échec.

Gouvernance & souveraineté : Déploiement **air-gap** et **on-premise**, gouvernance des données formalisée, **10 décisions d'architecture (ADR)**, registre de décisions métier, RGD. Certifié SecNumacadémie (ANSSI).

Données & NLP : Pipelines d'ingestion **multi-format** (9 handlers : PDF, Word, Excel, **OCR** Tesseract, RTF, **DXF/CAO**, **IFC/BIM**), classification par signature binaire, **extraction d'information structurée**, normalisation, **déduplication** SHA-256 et sémantique. **SQL**/PostgreSQL, pandas, NumPy, scikit-learn.

COMPÉTENCES — DÉVELOPPEMENT, OPS & TRANSVERSE

Backend & frontend : Python (34 400+ lignes en production, 71 modules, FastAPI, Pydantic, SQLAlchemy, structlog, pytest), **API REST** (6 endpoints, job store persistant, file asynchrone), webhooks, JWT. **TypeScript / React / Next.js 14** (28 composants, 5 900 lignes).

Ops & déploiement : Docker / Compose, Git (176 commits, 46 branches), CI/CD, Ansible, Nginx, déploiement cloud (Vercel, Railway), **on-premise** et auto-hébergement. **Monitoring** : Grafana, Langfuse, Prometheus (notions). Notions Kubernetes.

Développement assisté par IA : Cursor et Claude Code au quotidien — délégation cadrée, itération rapide, **revue critique systématique** et responsabilité du code livré.

Infrastructure & sécurité : Windows Server / Active Directory, Linux (Debian, RHEL), **VMware** (60 VMs, HA), réseaux (**CCNA** : VLAN, VPN, pare-feu), sauvegarde Veeam et PRA, **SIEM** (stack ELK déployée, projet noté 19/20), durcissement.

Transverse : Recueil des besoins et cadrage, vulgarisation devant des directions, **formation d'utilisateurs**, encadrement d'équipe, Agile, rédaction technique (ADR, procédures, mémoire). **Power BI**. Anglais professionnel (TOEIC 720).

RÉALISATIONS EN PRODUCTION

📌 SCALPEL — Copilote métier RAG souverain

Juin — Août 2026

Sogea Caroni — Groupe VINCI Construction (Roubaix) — Service Études de Prix — **concepteur unique**, 13 semaines

→ **Sujet de mémoire** : « Architecture et sécurisation d'un RAG souverain pour les Études de Prix BTP »

- **Le problème** : des dossiers d'appel d'offres de **plusieurs centaines de pages** (PDF textuels et scannés, Word, classeurs Excel de 20 ans, plans), sans nommage ni format normalisés. **Plusieurs heures** d'analyse manuelle par dossier, avant tout chiffrage.
- **La solution livrée** : pipeline d'ingestion **9 formats** → **RAG local** (Llama 3.1 8B, embeddings MiniLM CPU, Dense + BM25) → **extraction structurée de 23 champs** → **pré-remplissage automatique** des fiches Orchestra (Word) et d'un classeur Excel de **45 feuilles**, avec **citation de la source pour chaque valeur**.
- **La thèse défendue** : *le risque dominant n'est pas de manquer une information, c'est d'en retenir une fausse*. D'où une cascade de **5 couches de garde-fous** — nettoyage, anti-injection de prompt, **vérification d'ancrage > 85 %**, quarantaine, **post-validation par règles métier expertes** — et des **statuts d'abstention motivés** : l'outil répond « indéterminé » plutôt que d'inventer un prix.
- **Sécurité (cœur du mémoire)** : analyse et durcissement face aux menaces **OWASP LLM Top 10**, tests adversariaux, gouvernance des données formalisée en **10 ADR**.
- **Souveraineté totale** : architecture **100 % locale (air-gap)** — modèle, index et recherche sur la machine. Déploiement hors ligne malgré un **proxy DPI** d'entreprise bloquant les dépôts publics, sur un poste **sans droits administrateur**.
- **Fullstack & industrialisation** : **API FastAPI** (6 endpoints) + interface **Next.js/TypeScript** (workbench 4 zones, chat à citations cliquables, prévisualisation inline). **131 tests**, 20+ leçons formalisées. Développé en pilotant **Cursor**.
- **Relation métier** : recueil des besoins avec l'ingénieure Études de Prix référente, **15+ arbitrages métier** consignés, formulaire de retour d'expérience, formation, **soutenance devant jury** incluant le Directeur Études de Prix.

- **Agent 100 % autonome** en production : **2 exécutions/jour**, zéro intervention humaine. **53 sources** hétérogènes (flux, actualités, **8 portails ATS**) → déduplication → qualification par LLM → **injection directe dans le CRM** client.
- **Frugalité mesurée** : routage **GPT-4o-mini (80%)** → **Claude Sonnet (20%)** selon la complexité réelle, **ledger de coût temps réel** — **< 35 €/mois**. *Le bon modèle, pas le plus gros.*
- **Robustesse** : *structured output* contraint, **anti-injection**, **kill-switch**. **146 commits**. Client **non-technique** : specs FR, **RACI**, reconfiguration le jour même.

 **SignalHire** — plateforme SaaS d'agents & scoring IA

github.com/Isiah88/signalhire (code public) — agents de collecte multi-API, **scoring sémantique** par LLM avec justification, rotation de clés avec bascule sur quota, worker autonome, alertes, tableaux de bord. FastAPI + Next.js + PostgreSQL + Docker.

2025 — 2026

 **Prototypes & veille** : **NovaBuild** (multi-agents **LangGraph** + **CrewAI**, garde-fou anti-hallucination sur les prix) · **NexusGuard** (analyse par **graphe Neo4j** + Gemini, génération de correctifs) · **DeerFlow** (orchestration multi-agents) · **OptiFlux** (workflows **n8n**) · **ELK** + **Honeyiot** (SIEM & détection d'intrusion, noté 19/20).

EXPÉRIENCE PROFESSIONNELLE ANTÉRIEURE

Responsable de Département Infrastructures & Exploitation Numérique — ANADEN

Encadrement de **6 ingénieurs + 1 stagiaire**, gestion de prestataires helpdesk. **Pilotage de projets** : **9 serveurs déployés** dont **6 pour une banque centrale**, de l'étude des besoins à la mise en service. Infrastructure critique (VMware 60 VMs en HA, Windows Server/AD, Linux, réseau Cisco/Fortinet), **sauvegarde Veeam** et **PRA**, sécurité et gestion des accès, supervision, gestion d'incidents N1-N3, **reporting à la direction**.

Juin 2022 — Juin 2024

Chargé de Projets IT — PNUD (Nations Unies)

Pilotage de projets (Agile) en environnement **international anglophone**, recueil et formalisation des besoins, coordination multi-pays, **formation d'utilisateurs**, communication bilingue FR/EN auprès de parties prenantes institutionnelles.

2020 — 2022

FORMATION, CERTIFICATIONS & RÉFÉRENCES

Mastère DevOps MLOps Engineer — Bac+5 Data & I.A. ESAIP / ESSIN — titre RNCP niveau 7. <i>En alternance</i> — recherche contrat de professionnalisation. MLOps et pipelines de déploiement IA (MLflow, DVC), surveillance des modèles en production, Kubernetes, Terraform, CI/CD, Cloud, RGPD. Certification EXIN DevOps. Rythme 1 semaine de cours / 3 semaines en entreprise.	2026 — 2028	Références Stage VINCI Construction (Sogea Caroni) Tuteur : Directeur Études de Prix Utilisatrice référente : Ingénieure Études de Prix <i>Références disponibles sur demande.</i>
Bachelor Numérique — Administration des Infrastructures Sécurisées ESAIP / Saint-Jo Sup — spécialisation Intelligence Artificielle appliquée. Diplôme validé, mémoire soutenu en août 2026.	2025 — 2026	
Master 2 MIASHS — Data Science (Bac+5, Équivalence ENIC-NARIC) Mathématiques appliquées, statistiques, informatique, méthodes quantitatives.	2019	
Certifications : Google AI Essentials · SecNumacadémie (ANSSI) · CCNA (Cisco) Langues : Français (C2) · Anglais professionnel (TOEIC 720, 2 ans en organisation internationale)		
Qualités : Rigueur méthodologique et scientifique · autonomie et vitesse d'apprentissage · esprit critique · pédagogie · curiosité pour les métiers que j'outille.		